

Две оси сложности задачи: что означают числа в таблице участников

standings-edu

24 сентября 2026

1 О чём этот документ

На странице «Статистика участников» (и в профиле ученика) каждому ученику показывается строка чисел: прогресс, темп, соображает, аккуратность, часы. Здесь выписано, откуда берётся каждое из них — формулой и словами. Документ описывает *реализованную* модель: формулы соответствуют коду в `course_stats.go` и `course_fit.go`.

Курс — упорядоченный список задач группы: контесты страницы снизу вверх, внутри контеста — слева направо. Обозначения: i — ученик, j — задача курса, M — число задач, S_i — решённые учеником задачи курса, $\sigma(x) = 1/(1 + e^{-x})$.

Главное ограничение данных

Судья сообщает только **моменты посылок**. Из них можно восстановить, сколько человек *отлаживал* задачу, — и нельзя восстановить, сколько он над ней *думал*. Кто размышляет час, пишет решение и сдаёт с первой попытки, оставляет в данных ноль.

Это не мелочь: на реальном курсе (137 учеников, 378 задач, 80 тысяч посылок) **47% задач решаются одной посылкой, 35% занятий состоят из одной посылки**, а медианное занятие длится 10 минут. Прежняя модель мерила «активное время на задаче» и потому вырождалась: вес задачи совпадал с числом посылок по ней на +0,87 и лишь на +0,51 — с долей не осиливших её.

Поэтому модель построена на том, что *наблюдается*: на исходе попытки и числе попыток. Минуты как единица измерения сложности не используются.

Сводка: колонка $\rightarrow$ формула

Колонка	Что означает	Формула
Прогресс	доля пройденного по сложности	$P_i = (\sum_{j \in S_i} w_j) / \sum_j w_j$
Темп	сколько курса за неделю продвижения	$(\sum_{j \in S_i} w_j) / W_i $, делённое на медиану группы
По времени	тот же темп, свежее весит больше	вес недели $\gamma_w = 2^{-d_w/28}$
Соображает	шанс взять с первой попытки задачу обычной идейности	$\sigma(\theta_i^{\text{ym}} - \text{med}_j b_j)$
Аккуратность	во сколько раз меньше лишних посылок, чем ожидается	$\exp(-\rho_i \log R_i)$, делённое на медиану группы
Часов на судье	время между посылками	$\sum_j T_{ij}$
$\approx$ ч/нед	типичная недельная занятость	медиана по неделям с активностью (из 8)
$\approx$ неделя	прогноз до конца курса	остаток веса / текущий темп
Сейчас на	фронт	последняя решённая по порядку курса
Сигналы	застрял / пропустил	посылка $> 3 \times$ обычного / дальше решено ≥ 2
Флаги	невероятные серии	разд. 9

2 Цена задачи

Цена w_j измеряется в «**обычных задачах курса**»: медианная задача стоит 1,0, вдвое более дорогая — 2,0. Единица намеренно не минуты: минут в данных нет.

Цена собирается из двух осей. Они меряют разное — связь между ними +0,46 в эмпирических оценках — поэтому складываются явно, а не подменяют друг друга. Эти же две оси определяют и показатели ученика (разд. 5).

Ось 1. Идейность — надо ли догадаться. Модель Раша по исходу «взял / не взял» среди *пробовавших*:

$$\text{Pr}(\text{ученик } i \text{ решит } j \mid \text{пробовал}) = \sigma(\theta_i - b_j).$$

θ_i — сила ученика, b_j — идейность задачи. Подгонка — покоординатный Ньютон с регуляризацией $\lambda = 1$ (без неё задача, которую решили все, уводит b_j в $-\infty$).

Ось 2. Сложность реализации — много ли возни, когда идея уже есть. Двусторонняя медианная подгонка по числу посылок k_{ij} до зачёта:

$$\log k_{ij} = \alpha_i + e_j + \epsilon,$$

чередованием медиан: $e_j = \text{med}_i(\log k_{ij} - \alpha_i)$, затем $\alpha_i = \text{med}_j(\log k_{ij} - e_j)$, 40 итераций. Медианы, а не средние — чтобы один застрявший не перекашивал оценку.

Цена. Оси приводятся к безразмерной шкале робастным z (медиана и медианное абсолютное отклонение) и складываются:

$$w_j = \frac{\exp(0,65 z(e_j) + 0,35 z(b_j))}{\text{med}_k \exp(0,65 z(e_k) + 0,35 z(b_k))}.$$

Реализация весит больше: именно она определяет, сколько времени задача реально съедает.

Почему обе оси нужны. Задача «Улитка» (вывести формулу без `if` и циклов) — её *не осилили 27%*, но решившие сдавали одной посылкой. По одной лишь реализации она попадала в 46-й перцентиль, вровень с рядовым упражнением; с идейностью — в 87-й. Обратный случай — «Гоблины и шаманы»: берут 93%, но по 7 посылок каждый; была *самой дорогой задачей курса*, стала 95-м перцентилем.

Оценка по условию как априор

Обе подгонки требуют данных, которых в начале курса нет. Недостающее заменяет оценка сложности, сделанная по условию задачи (моделью или преподавателем) и лежащая в `data/task_ratings.json`. Она хранится в *наблюдаемых* величинах — `idea_rate` (доля дошедших, кто придумает решение сам) и `impl_attempts` (посылок у того, кто уже придумал), — чтобы её можно было сверить с фактом; абстрактную «сложность от 1 до 5» сверить не с чем.

Имена ключей называют *ось*, а суффикс — наблюдаемую единицу. Файл прежнего формата (`solve_rate / attempts`) читать отказываются: там лежала доля решивших задачу вообще, на этом курсе 0,85–0,99 при медиане 0,97. Прочитанная как идейность, она выставила бы почти всем задачам 1 балл, и априор весом в 64 ученика задавил бы этим данные.

Оценка переводится в те же шкалы, в которых работают подгонки, и смешивается с ними по числу наблюдений:

$$b_j \leftarrow \frac{n_j b_j + K b_j^{\text{оц}}}{n_j + K}, \quad b_j^{\text{оц}} = -\text{logit}(\text{доля решивших}),$$

и так же для реализации с $e_j^{\text{оц}} = \log(\text{число посылок})$. Здесь n_j — число учеников, прошедших через задачу, а K — вес априора. Перевод точный, а не подогнанный: при силе ученика $\theta = 0$ вероятность взять задачу равна $\sigma(-b)$, откуда и берётся $b^{\text{оц}}$.

Читается так: оценка стоит K учеников. У задачи с сотней решивших она почти не видна, у новой — единственный источник.

K разное по осям, и это измерено. Ось оценивалась на половине когорты и сверялась с оценкой по другой половине (378 задач, 130 учеников):

Ось	только данные	$K = 16$	$K = 64$	$K = 256$	только оценка
Идейность	+0,375	+0,387	+0,416	+0,391	+0,345
Реализация	+0,882	+0,869	+0,812	+0,702	+0,608

Отсюда $K_{\text{идей}} = 64$ и $K_{\text{реал}} = 6$ (подтверждённой оценке — вдвое больше). Причина асимметрии содержательная: **реализацию данные знают хорошо** (надёжность оси при делении когорты пополам 0,92), а **идейность — почти не знают** (0,48, потолок для любого предсказателя 0,70): задачу бросают не только потому, что она трудная, но и потому, что ушли из курса. Там оценка по условию перевешивает всю когорту.

Сколько это даёт. Слепая проверка на выгрузке курса: 64 задачи оценены по одним условиям, эталон — оценка по 69 ученикам, не пересекающимся с обучающей половиной. Оценка без единого ученика совпала с эталоном на +0,77 — точнее, чем данные по 34 ученикам (+0,74). Оценка вместе с пятью учениками дала +0,79, обойдя полные данные по 68 (+0,78). На полных данных смесь даёт +0,85 против +0,78 у данных в одиночку. Разброс от выборки к выборке падает с $\pm 0,13$ до $\pm 0,02$ — для интерфейса это важнее среднего: цена задачи перестаёт прыгать при каждой генерации.

Проверено и обратное: те же оценки, *перемешанные между задачами*, дают +0,34 против +0,61 вовсе без априора. Плохой априор вредит, то есть работает содержание оценки, а не факт усреднения.

Очередь проверки

Сплошная валидация 378 задач съест время преподавателей и почти ничего не изменит. В админке (/standings/admin/task-ratings) показывается очередь задач, где оценка *спорит* с наблюдаемым, отсортированная по величине расхождения, взвешенной на охват. В очереди видны сырые наблюдаемые — доля взявших с первой посылки и число посылок, — а не итоговая цена: иначе преподаватель подтверждал бы число, на которое сам же и повлиял. Правятся оси в баллах 1..10; в файле лежат наблюдаемые величины.

Идейность сверяется с долей взявших с *первой посылки*, а не с долей решивших вообще: последняя в этом курсе равна 97% почти везде и с идейностью не соотносится никак.

Расхождение полезно и само по себе, независимо от цен. «Оценка говорит сложно, а берут все с первой попытки» — вероятно, решение разошлось по группе или тесты слабые. «Оценка говорит просто, а половина не осилила» — обычно виновата не задача, а формулировка, формат вывода или недостижимый на Python лимит.

Чего здесь нет: поправки на редкость

Прежняя модель домножала вес на $(1/p_j)^{1/2}$ против survivorship bias: редкие задачи якобы решают сильные и быстрые. Проверка на данных: медианная сила решивших равна $\times 1,00$ в каждом из 39 контекстов (разброс 0,98–1,06). Поправлять нечего. При этом поправка раздувала веса до $\times 3$ — сильнее всего в «разнобоях» и в выпускной контрольной «любые 15 задач из 30», где низкое p_j означает не сложность, а *необязательность*.

Теперь она не нужна и по устройству: обе подгонки двусторонние и сами отделяют силу ученика от свойства задачи. Если задачу взяли только сильные, это видно по их θ_i , а не выдаётся за лёгкость задачи.

3 Прогресс

$$P_i = \frac{\sum_{j \in S_i} w_j}{\sum_{j=1}^M w_j} \in [0, 1].$$

Доля пройденного *по сложности*: две простые задачи весят меньше одной трудной. Рядом в интерфейсе — «решено / всего» в штуках.

4 Темп

Пусть W_i — множество календарных недель, в которые ученик взял хотя бы одну задачу курса. Сырой темп:

$$\tau_i = \frac{\sum_{j \in S_i} w_j}{|W_i|},$$

показываемое число — $\tau_i / \text{med}_k \tau_k$ по когорте.

Читается так: сколько обычных задач курса ученик закрывает за неделю продвижения. $\times 1$ — как типичный ученик когорты.

Почему знаменатель — недели с решённой задачей, а не все недели с посылками. У преподавателя, который годами что-то шлёт на судью, недель с посылками 294, а недель с решённой задачей — 76. По первому знаменателю человек, прошедший *весь курс целиком*, оказывался 131-м из 137; по второму — 19-м. Неделя с одной случайной посылкой — это не неделя занятий. Безуспешные усилия при этом не теряются: они видны в часах на судье и в сигнале «застрял».

По времени: текущая форма

Тот же темп с экспоненциальным забыванием. Неделя, закончившаяся d_w дней назад, получает вес $\gamma_w = 2^{-d_w/H}$, $H = 28$ дней:

$$\tau_i^{\text{тек}} = \frac{\sum_{w \in W_i} \gamma_w \sum_j \text{решена в } w w_j}{\sum_{w \in W_i} \gamma_w}.$$

Когда число не показывается

При $|S_i| < 5$ или $|W_i| < 2$ вместо темпа выводится «мало данных».

5 Соображает и аккуратность

Две оси задачи дают два разных показателя ученика.

Соображает — берёт ли головой:

$$\text{Соображает}_i = \sigma(\theta_i^{\text{ym}} - \text{med}_j b_j),$$

шанс взять с первой попытки задачу *обычной для курса идейности*. Здесь θ_i^{ym} — сила при *известной* трудности: в правдоподобии стоит идейность b_j из разд. 2, а не подгоняемый заново порог. Это важно — если подгонять и то и другое по одним данным, сильная серия объясняется задним числом через самого ученика. Задачи входят с весом

$$\omega_j = \sigma(1,5 \cdot (z(b_j) - z(e_j))),$$

то есть тем большим, чем сильнее в задаче перевешивает идея, а не возня. Априорное распределение силы — $\mathcal{N}(0, 1,5)$: без него ученик, взявший с первой попытки все 25 своих задач, улетает в потолок шкалы.

Аккуратность — попадает ли с первого раза:

$$R_i = \frac{1 + \sum_j (1 - \omega_j) (k_{ij} - 1)}{1 + \sum_j (1 - \omega_j) \hat{k}_j}, \quad \hat{k}_j = e^{e_j} - 1,$$

отношение фактических лишних посылок к ожидаемым на этих задачах, по задачам с перевесом реализации. Показывается как $\exp(-\rho_i \log R_i)$, делённое на медиану группы, где $\rho_i = E_i/(E_i + 6)$ — усадка к «как обычно» по объёму свидетельств (E_i — знаменатель). Нормировка по когорте не косметика: лишние посылки суммируются арифметически, а ожидание берётся из медианной подгонки, и на скошенном распределении (52% задач берут с первой, среднее 2,3 при медиане 1) без неё медиана выходила 0,62 вместо 1,00.

Насколько это работает

Деление пула задач пополам, выгрузка курса (378 задач, 130 учеников, 30 тысяч посылок):

Показатель	Надёжность	Медиана	Межквартильный размах
Темп	0,94	×1,00	0,78–1,27
Соображает	0,81	53%	44–61%
Аккуратность	0,87	×1,00	0,82–1,23

Ни один показатель не вырождается: самое частое значение встречается у 3–6% учеников, в потолок шкалы не упирается никто.

Связи между показателями. Темп с двумя другими не связан (+0,06 и −0,02) — сколько человек сидит за курсом — это про желание и время, а не про способности. А «соображает» и «аккуратность» связаны на +0,69: кто соображает, тот обычно и отлаживает меньше.

Это свойство учеников, а не дефект счёта, и прятать его нельзя — иначе преподаватель прочтёт два числа как независимые оценки. Опускать связь ниже можно, но дорого: жёсткое деление пула задач пополам даёт $+0,60$ ценой падения надёжности «соображает» с $0,81$ до $0,69$, то есть треть порядка становится шумом. Выбрана надёжность, а связь названа прямо в легенде.

Чего здесь нет: «уровня» ученика

Сначала вторым числом была **сила** — доля курса, которая ученику по плечу, по модели Раша на исходе «пробовал $\rightarrow$ решил». Она вырождалась. В этом курсе **97% начатых задач в итоге берут**: ученик долбит задачу, пока не возьмёт. Значит «сможет ли решить» почти детерминировано, разделять людей нечем — и на реальной группе **86% учеников получали ровно 100%**, а тот, кто не решил ничего, показывал 98%.

Вывод стоит принять прямо: «*что может*» *этими данными не измеряется*. Измеряется «как берёт»: доля решений с первой попытки равна 52%, и разброс там настоящий.

Проверялись и другие кандидаты. *Цена взятых задач* («уровень») даёт хороший разброс, но совпадает с прогрессом на $+0,93$ — это он и есть, курс упорядочен по сложности. *Сила по числу посылок* вырождается иначе: медианная подгонка ставит 88% учеников ровно в ноль. *Охват* (Раш по исходу «дорешал или бросил») хорошо отделяется от аккуратности ($+0,16$), но надёжен лишь на $0,62$ и упирается в потолок у тех, кто ничего не бросил.

Отдельно проверялся **перекос** — разность «соображает» и «аккуратности» как подпись профиля («берёт головой» против «берёт усидчивостью»). Он ортогонален уровню ($+0,05$), но **надёжен всего на $0,38$** : при делении пула задач пополам половинки сходятся на $+0,24$. Это шум, и в интерфейс он не выведен.

6 Часы на судье

Посылки сортируются по времени; пауза больше $\tau = 45$ мин начинает новое **занятие**. Внутри занятия пауза перед посылкой приписывается задаче этой посылки, первая посылка занятия получает надбавку $\delta_0 = \min(\text{med}(\text{внутрисессионных пауз}), 10 \text{ мин})$.

$$A_i = \sum_{j=1}^M T_{ij}.$$

Как это читать. Это время *между посылками* — работа на судье, отладка. Это **не** «время над задачами»: обдумывание до первой посылки судья не показывает. Колонка полезна, чтобы увидеть, кто много бьётся; она не годится для сравнения «сколько стоила задача» — ради этого и введена цена.

Перерывы любой длины (выходные, каникулы) в A_i не попадают. Занятия строятся по *всем* посылкам ученика, но в A_i идут только задачи этого курса.

7 Сигналы: застрял и пропустил

Застрял: задача не взята, но посылок по ней уже больше чем в $z^* = 3$ раза против обычного для неё числа (медиана по решившим, при не менее чем 3 решивших). Считается в посылках, а не в минутах — по той же причине, по которой минуты не годятся для цены.

Пропустил: по задаче были попытки, она не взята, а дальше по курсу решено ≥ 2 задач.

Каждого вида показывается не больше четырёх.

8 Прогноз

$$\text{неделя} = \frac{\sum_j w_j - \sum_{j \in S_i} w_j}{\tau_i^{\text{тек}}}$$

— остаток курса по текущему недельному темпу. Грубая оценка: предполагает, что форма сохранится, а оставшиеся задачи по сложности похожи на пройденные.

9 Флаги: невероятные серии

Флаг — сигнал для *личной проверки* преподавателем, не вердикт.

Чего здесь больше нет

Детекторов было четыре, с абсолютными порогами, и они помечали **69% учеников** — то есть не помечали ничего. Главный из них, «пачечная сдача» (4+ задач за занятие при личном времени меньше половины типичного), срабатывал на обычной учёбе: если решить четыре задачи за один присест, занятие делится между ними, и личное время оказывается мало *по построению*. На него приходилось 203 флага из 336.

Один вопрос вместо четырёх

Эпизод — непрерывная по времени серия решений «с первой попытки» длиной не меньше 4; серию рвёт любое решение не с первой попытки или разрыв больше 6 часов. Для эпизода E считается вероятность, что он получился сам собой:

$$\Pr(E) = \prod_{j \in E} \sigma(\theta_{i \setminus E}^{\text{ft}} - b_j^{\text{ft}}),$$

где b_j^{ft} — порог задачи по исходу «взял с первой попытки» (та же модель Раша), а $\theta_{i \setminus E}^{\text{ft}}$ — сила ученика, оценённая по **остальной его работе, без этого эпизода**.

Исключение эпизода из оценки принципиально. Иначе подозрительная серия объясняет сама себя: модель решает, что человек просто сильный, — и тем увереннее, чем меньше у него другой истории. Проверяемая гипотеза именно такая: *мог ли этот ученик, судя по всему остальному, выдать такую серию случайно*. Если другой истории нет вовсе, берётся нулевая сила, то есть мерка среднего ученика когорты.

Порог — с поправкой на число проверок у этого ученика:

$$\Pr(E) < \frac{\alpha}{|\{\text{эпизодов ученика}\}|}, \quad \alpha = 0,02.$$

Тот, кто решает много, имел больше возможностей наткнуться на длинную серию случайно, — поэтому его отдельная серия должна быть тем экстремальнее.

Что это даёт. Сильный ученик, взявший пять лёгких задач с первой попытки, не помечается: для него это ожидаемо. Слабый, взявший пять трудных, — помечается. На реальных данных: **10 эпизодов у 9 учеников (7%)** вместо 336 флагов у 69%.

Что делает разметка

До разметки преподавателем посылки эпизода исключаются из всей математики темпа (цены когорты, темп, сила). «Сам решил» возвращает эпизод в подсчёт; «перенос»/«нарушение» оставляют исключённым навсегда. Решённые задачи при этом остаются решёнными — прогресс не страдает.

10 Константы

Обозначение	Значение	Смысл
τ	45 мин	разрыв, начинающий новое занятие
δ_0	≤ 10 мин	надбавка на «вход» в занятие
H	28 дней	полупериод забывания для текущей формы
доли осей	0,65/0,35	реализация / идейность в цене задачи
λ	1	регуляризация модели Раша
$K_{\text{идей}}$	64	вес оценки по условию для идейности
$K_{\text{реал}}$	6	то же для реализации (данные знают её лучше)
подтверждённой	$\times 2$	оценке преподавателя доверия вдвое больше
β	1,5	резкость разведения осей в весе задачи ω_j
σ^2	1,5	априорная дисперсия силы в «соображает»
усадка аккуратности	6	ожидаемых лишних посылок до полного доверия
итераций	40 / 200	медианная подгонка / Ньютон
z^*	3	порог сигнала «застрял», в посылках
порог показа темпа	5 задач, 2 недели	иначе «мало данных»
когорты для нормировки	≥ 5 учеников	иначе сырая шкала
α	0,02	бюджет ложных флагов на ученика
длина эпизода	≥ 4	решений подряд с первой попытки
окно эпизода	6 ч	большой разрыв рвёт серию
сигналов на ученика	≤ 4	каждого вида

11 Границы применимости

- Число посылок известно только для сайтов, отдающих посылки (informatics, codeforces, ejudge). Задачи ACMR входят в прогресс и в ось идейности, но не в ось реализации.
- Цена — величина *сравнительная внутри курса*. «Вдвое дороже обычной задачи этого курса» — да; «занимает 40 минут» — нет, таких данных судья не даёт.
- В первые недели нового курса решивших мало, обе подгонки шумные, и цены близки друг к другу. Они уточняются при каждой генерации.
- Темп меряет продвижение, а не усидчивость: неделя без единой взятой задачи в знаменатель не идёт. Усилия без результата видны в часах на судье и в сигнале «застрял».
- Флаги ловят только один паттерн — невероятную серию «с первой попытки». Списывание, размазанное по времени и перемежаемое ошибками, не ловится ничем и ловиться не должно: цена ложного обвинения выше.
- «Соображает» не говорит, что ученику по силам, — только как он берёт то, за что взялся. Потолка сложности в этих данных не видно (см. раздел про «уровень»).
- «Соображает» и «аккуратность» связаны на +0,69. Читать их как две независимые оценки нельзя; интересны расхождения, а не сумма.
- Идейность держится на оценке по условию, а не на данных: проверить её по посылкам можно лишь косвенно (надёжность эмпирической оси 0,48). Если оценщик систематиче-

ски ошибается на каком-то классе задач, данные этого почти не поправят — в отличие от реализации.

- Оценщик по условию не знает вашего судьи: лимит времени, непроходимый на Python, странный формат вывода, кривые тесты — всё это гонит реализацию вверх, и видно это только в данных. Поэтому по реализации априор уступает данным ($K_{\text{реал}} = 6$); по идейности, наоборот, данные почти ничего не говорят, и там вес априора велик.
- Измерена точность *одного* оценщика. Согласованность между оценщиками (вторая модель, второй преподаватель) не проверялась.

12 Где это в коде

- `internal/standings/course_fit.go` — подгонки (`twoWayMedianFit`, `raschFit`), сила при известной трудности (`raschAbilityKnown`) и робастный z .
- `internal/domain/models.go` — `TaskRating`: две оси, их перевод в шкалы модели и в баллы 1..10 для правки человеком.
- `internal/standings/course_review.go` — очередь задач на проверку оценок.
- `internal/standings/course_stats.go` — порядок курса, занятия и T_{ij} , цена задач (`fitCourseModel`), числа ученика (`computeStudentCourseStats`), флаги (`detectCourseFlags`).